

Évaluation de la robustesse des LLM aux paraphrases en biologie

Projet de Licence

NEFISA MAHAMAT MALIK

ENASTIC
Licence Informatique

2025–2026

- Les **LLM** (ChatGPT, FLAN-T5, etc.) répondent à des questions scientifiques.
- Une simple reformulation (paraphrase) peut modifier la réponse.
- Problème majeur pour la **fiabilité** dans les domaines éducatifs et médicaux.
- La biologie, avec sa terminologie précise, sert de domaine d'étude.

Question centrale

« Un LLM répond-il de façon cohérente quand on lui pose la même question avec des mots différents ? »

Objectif : mesurer quantitativement cette robustesse sur des questions de biologie.

Objectifs

- ➊ Générer **1000 questions** de biologie.
- ➋ Produire automatiquement des **paraphrases**.
- ➌ Interroger le LLM avec la question originale et sa paraphrase.
- ➍ Comparer les réponses par **similarité cosinus**.
- ➎ Calculer un **score de robustesse** et un **taux de contradiction**.
- ➏ Fournir une **interface web** pour visualiser les résultats.

Qu'est-ce qu'un LLM ?


Definition

LLM (Large Language Model) : réseau de neurones profond entraîné sur des milliards de textes pour prédire le mot suivant.

Exemples : GPT, FLAN-T5, BERT, LLaMA.

Modèle utilisé : google/flan-t5-base (250 millions de paramètres).

Architecture du système



Flot : Utilisateur → Streamlit → FastAPI → LLM → Analyse → Résultats.

- Notebook avec **GPU T4** gratuit.
- Chargement de `flan-t5-base` et du modèle de similarité `all-MiniLM-L6-v2`.
- Génération de 1000 questions de biologie (thèmes : ADN, cellule, mitochondrie, etc.).
- Paraphrases par **substitution lexicale** (ex. « rôle » « fonction »).
- Calcul de la similarité cosinus entre les deux réponses.
- Sauvegarde des résultats en **CSV** sur Google Drive.

Backend FastAPI : trois endpoints REST

- POST /paraphrase : génère des paraphrases.
- POST /evaluate : exécute le pipeline et retourne le score.
- GET /history : consulte l'historique SQLite.

Frontend Streamlit

- Saisie d'une question.
- Affichage de la réponse originale, du score de robustesse et d'un graphique.
- Consultation de l'historique.

Métrique	Valeur
Similarité moyenne	0,72
Taux de contradiction (sim < 0,3)	11%

Exemple concret

- Question : « *Quel est le rôle de l'ADN ?* »
- Réponse originale : « *a phylogenetic basis* »
- Paraphrase : « *À quoi sert l'ADN ?* »
- Réponse après paraphrase : « *stores genetic information* »
- Similarité : **0,21** contradiction.

Difficultés rencontrées

- **Temps d'exécution** : 45 min pour 1000 questions sur Colab (risque de déconnexion).
- **Réponses aberrantes** : FLAN-T5 donne parfois des réponses hors sujet.
- **Paraphrases limitées** : substitution simple, pas de reformulation naturelle.
- **Gestion mémoire** : vidage du cache GPU nécessaire toutes les 200 questions.

Conclusion

- Le LLM `flan-t5-base` **n'est pas parfaitement robuste** (11% de contradictions).
- L'outil développé permet de tester facilement n'importe quelle question.
- Importance de **valider les LLM sur des paraphrases** avant déploiement.

Merci

Questions ?